รายงานฉบับสมบูรณ์: การประเมิน Qwen3-VL สำหรับ Chest X-ray บน RTX 5070 และ LANTA A100

วันที่ทดลอง: 23 กันยายน 2026

สถานะการศึกษา: Development/Pilot (`development_pilot_only`)

ขอบเขตข้อมูล: ใช้เฉพาะข้อมูลจาก official V3 train split; ไม่เปิด confirmatory Test

หน่วยวิเคราะห์หลักด้านคุณภาพ: ผู้ป่วย

หน่วยวิเคราะห์รอง: ภาพ

บทสรุป

การทดลองแยกคำถามออกเป็นสี่ส่วน: ความเร็วต่อ GPU (A), คุณภาพและผลของ precision (B), batch scaling (C1) และ multi-GPU scaling (C2) จากนั้นเพิ่ม Set D เพื่อทดสอบ 30B MoE และ 32B dense ซึ่งไม่สามารถโหลดบน RTX 5070 ได้

ผลหลักมีดังนี้

- ที่ batch 1 การใช้ A100 หนึ่งใบไม่ทำให้โมเดล 2B-8B เร็วขึ้น RTX 5070 ให้ pipeline throughput สูงกว่าในทุก profile โดย A100 speedup เท่ากับ 0.652, 0.703 และ 0.786 เท่า จึงไม่ผ่านเกณฑ์ 1.5 เท่าทั้งหมด
- กฎเลือก comparator ที่กำหนดไว้บน Development เลือก `4b-bf16` ด้วย patient-level balanced accuracy 0.6867
- บน A100 การเพิ่ม batch จาก 1 เป็น 8 เพิ่ม pipeline throughput จาก 10,894 เป็น 41,614 images/hour โดยไม่เกิด OOM หรือ parse failure
- เมื่อแบ่งข้อมูลและ CPU affinity ถูกต้อง C2 ให้ speedup 1.991 เท่าบน 2 GPUs และ 3.914 เท่าบน 4 GPUs คิดเป็น scaling efficiency 99.53% และ 97.86%
- 30B และ 32B เกิด CUDA OOM จริงบน RTX 5070 แต่รันสำเร็จบน 2×A100 บน Development 549 ผู้ป่วย ทั้งสองโมเดลมี balanced accuracy สูงกว่า 4B แต่เพิ่มเพียง 0.0404 และ 0.0468 จึงไม่ถึง margin +0.05 ที่กำหนดไว้ นอกจากนี้ 32B ทำให้ PNEUMONIA recall ลดลง 0.1086 ซึ่งเกินขอบเขต -0.03
- งานทั้งหมดใช้ 9.3200 allocated GPU-hours จาก planning ceiling 24 GPU-hours

ข้อสรุปที่ข้อมูลรองรับคือ LANTA มีประโยชน์ด้าน **capacity, batching และ parallelism** แต่ไม่ให้ความเร็วต่อ GPU สำหรับ workload batch 1 ที่ทดสอบ และยังไม่มี large model ใดผ่าน quality gate ที่กำหนดไว้ งานนี้ไม่ใช่หลักฐานเชิงคลินิกและไม่ใช่ ผล confirmatory

1. ข้อมูล โมเดล และวิธีทดลอง

1.1 ชุดข้อมูลที่ใช้จริง

ต้นทางคือ Kermany, Zhang, and Goldbaum Mendeley Data V3 ซึ่ง canonical manifest มี 5,856 ภาพจาก 3,081 ผู้ป่วย การทดลองทั้งหมดในรายงานนี้ดึงจาก official train split และแยก labels ออกจาก blind inference manifest

ชุดทดลอง	ภาพ	ผู้ป่วย	NORMAL	PNEUMONIA	การใช้งาน
Performance-1000	1,000	859	500	500	A และ C1
Quality-Development-600	600	549	300	300	B และ D
Scaling-2000	2,000	1,529	1,000	1,000	C2

Dataset manifest SHA-256 คือ `1b4cff13ee5615de5df283372bc91330cdc8ba4f4b5c2e95d1b878329ed5aff0` ทุก config ระบุ `source_split: train`, `study_role: development` และ `confirmatory_unlocked: false`

1.2 โมเดลที่ทดสอบ

Profile	Model ID	Revision	Precision	สถาปัตยกรรม
`2b-bf16`	`Qwen/Qwen3-VL-2B-Instruct`	`89644892e4d85e24eaac8bacfd4f463576704203`	BF16	dense
`4b-bf16`	`Qwen/Qwen3-VL-4B-Instruct`	`ebb281ec70b05090aa6165b016eac8ec08e71b17`	BF16	dense
`8b-nf4`	`Qwen/Qwen3-VL-8B-Instruct`	`0c351dd01ed87e9c1b53cbc748cba10e6187ff3b`	NF4	dense
`8b-bf16`	`Qwen/Qwen3-VL-8B-Instruct`	`0c351dd01ed87e9c1b53cbc748cba10e6187ff3b`	BF16	dense
`30b-a3b-bf16`	`Qwen/Qwen3-VL-30B-A3B-Instruct`	`9c4b90e1e4ba969fd3b5378b57d966d725f1b86c`	BF16	MoE
`32b-bf16`	`Qwen/Qwen3-VL-32B-Instruct`	`0cfaf48183f594c314753d30a4c4974bc75f3ccb`	BF16	dense

1.3 สภาพแวดล้อม

รายการ	Local	LANTA
GPU	GeForce RTX 5070, 12,343,050,240 bytes	A100-SXM4-40GB, 42,409,000,960 bytes/GPU
Python	3.12.13	3.11.10
PyTorch	2.14.0+cu130	2.7.1+cu126
CUDA runtime	13.0	12.6
Transformers	5.17.0	5.17.0
Accelerate	1.15.0	1.15.0
bitsandbytes	0.50.2	0.50.2

การเทียบ A จึงเป็นการเทียบแพลตฟอร์มที่ใช้งานได้จริง ไม่ใช่การแยกผลของ GPU silicon ภายใต้ software stack เดียวกัน

1.4 Metric และกฎการนับ

- Primary quality metric: patient-level balanced accuracy
- Metrics เพิ่มเติม: accuracy, macro-F1, uncertainty rate, coverage และ precision/recall/F1 แยกคลาส
- Patient prediction: strict majority จากทุกภาพของผู้ป่วย; tie, missing, runtime failure และ parse failure กลายเป็น `UNCERTAIN`
- `UNCERTAIN` ไม่ถูกตัดออกจากตัวหารของ accuracy, balanced accuracy หรือ recall
- ช่วงความเชื่อมั่น: patient-stratified bootstrap 2,000 replicates, seed 20260923
- Paired comparison: paired patient bootstrap และ exact two-sided McNemar test
- Throughput ใช้เฉพาะ measured batches ที่สำเร็จและไม่รวม model loading
- Peak VRAM รวม warm-up; model loading, generation, pipeline และ complete job elapsed แยกรายงานคนละขอบเขต
- Hardware speedup: local pipeline time / A100 pipeline time
- Multi-GPU speedup: median 1-GPU inference time / median k-GPU inference time

2. Experiment A - ความเร็วต่อ GPU

แต่ละ profile รัน 5 รอบแบบ fresh process บนรายการ 1,000 image-equivalents ลำดับเดียวกัน batch 1 และ GPU 1 ใบ ผลทำนายครบ 1,000/1,000 เป็น status ok ทุกครั้ง

2.1 Timing, throughput และ VRAM

ค่าทั้งหมดเป็น median ของ 5 รอบ หน่วยเวลาเป็นวินาที และ VRAM เป็น GiB

Profile	Platform	Load	Generation total	Pipeline total	Generation img/h	Pipeline img/h	Amortized generation p50	p95	Peak allocated	Peak reserved
2B BF16	Local	0.837	157.983	176.552	22,787.3	20,390.6	0.1579	0.2164	4.06	4.12
2B BF16	A100	2.983	246.584	271.257	14,599.5	13,271.5	0.2573	0.2949	4.04	4.08
4B BF16	Local	1.232	212.803	231.581	16,917.0	15,545.3	0.2194	0.2827	8.38	8.43
4B BF16	A100	5.639	304.437	329.219	11,825.1	10,935.0	0.3286	0.3766	8.36	8.39
8B NF4	Local	3.142	332.465	351.066	10,828.2	10,254.5	0.3438	0.4249	6.18	6.23
8B NF4	A100	11.723	421.769	446.466	8,535.5	8,063.3	0.4657	0.5297	6.15	6.26

Batch-level pipeline latency medians:

Profile	Platform	Pipeline latency p50	Pipeline latency p95
2B BF16	Local	0.1741	0.2351
2B BF16	A100	0.2785	0.3235
4B BF16	Local	0.2334	0.3008

Profile	Platform	Pipeline latency p50	Pipeline latency p95
4B BF16	A100	0.3472	0.4050
8B NF4	Local	0.3593	0.4466
8B NF4	A100	0.4838	0.5575

Peak process RSS medians ซึงเป็น host-memory metric:

Profile	Local GiB	A100 job GiB
2B BF16	4.83	4.69
4B BF16	9.13	8.99
8B NF4	17.34	17.14

2.2 Speedup gate

Profile	A100 speedup	95% bootstrap CI	เกณฑ์ >=1.5 และ lower CI >1	ผล
2B BF16	0.652	[0.635, 0.655]	ไม่ผ่าน	Local เร็วกว่า 1.53×
4B BF16	0.703	[0.697, 0.714]	ไม่ผ่าน	Local เร็วกว่า 1.42×
8B NF4	0.786	[0.769, 0.811]	ไม่ผ่าน	Local เร็วกว่า 1.27×

ข้อสรุปของ A จำกัดอยู่ที batch 1 และ model sizes 2B-8B การที throughput gap แคบลงเมือโมเดลใหญ่ขึ้นไม่ใช่หลักฐานว่า A100 จะเร็วกว่า ณ ขนาดใดขนาดหนึง

3. Experiment B - คุณภาพบน Development

ชุด B มี 600 ภาพจาก 549 ผู้ป่วย กฎเลือก best-local comparator คือ patient-level balanced accuracy สูงสุด ตามด้วย macro-F1 สูงกว่า, uncertainty ต่ำกว่า และ declared order `2b-bf16`, `4b-bf16`, `8b-nf4`

3.1 Patient-level metrics

ค่าทีอยู่ในวงเล็บคือ 95% bootstrap CI

Profile	n	Accuracy	Balanced accuracy	Macro-F1	Uncertainty	Coverage	Image BA
2B BF16	549	0.6576 [0.6266, 0.6922]	0.6651 [0.6344, 0.6988]	0.6391 [0.6001, 0.6804]	0.0182	0.9818	0.6733
4B BF16	549	**0.6812 [0.6466, 0.7159]**	**0.6867 [0.6517, 0.7216]**	**0.6800 [0.6407, 0.7182]**	0.0291	0.9709	**0.7000**
8B NF4	549	0.5738 [0.5337, 0.6120]	0.5771 [0.5364, 0.6153]	0.5817 [0.5389, 0.6210]	0.0437	0.9563	0.5967
8B BF16	549	0.4208 [0.3789, 0.4608]	0.4180 [0.3761, 0.4579]	0.5057 [0.4611, 0.5480]	0.3643	0.6357	0.4417

กฎทีกำหนดไว้เลือก `4b-bf16` ตัวเลขของ 8B BF16 ไม่สนับสนุนสมมติฐานว่า precision ทีสูงขึนจะเพิมคุณภาพภายใต้ prompt/parser ชุดนี เพราะ uncertainty สูงถึง 36.43% ในระดับผู้ป่วย

3.2 Patient-level per-class metrics

Profile	Class	Support	Predicted	Precision	Recall	F1
2B BF16	NORMAL	282	123	0.8943	0.3901	0.5432
2B BF16	PNEUMONIA	267	416	0.6034	0.9401	0.7350
4B BF16	NORMAL	282	162	0.8457	0.4858	0.6171
4B BF16	PNEUMONIA	267	371	0.6388	0.8876	0.7429
8B NF4	NORMAL	282	192	0.6667	0.4539	0.5401
8B NF4	PNEUMONIA	267	333	0.5616	0.7004	0.6233
8B BF16	NORMAL	282	216	0.6759	0.5177	0.5863
8B BF16	PNEUMONIA	267	133	0.6391	0.3184	0.4250

95% CI ของ recall:

Profile	NORMAL recall CI	PNEUMONIA recall CI	Uncertainty CI	Coverage CI
2B BF16	[0.3333, 0.4504]	[0.9138, 0.9663]	[0.0073, 0.0310]	[0.9690, 0.9927]
4B BF16	[0.4255, 0.5426]	[0.8502, 0.9213]	[0.0164, 0.0437]	[0.9563, 0.9836]
8B NF4	[0.3972, 0.5142]	[0.6441, 0.7566]	[0.0273, 0.0619]	[0.9381, 0.9727]
8B BF16	[0.4610, 0.5745]	[0.2622, 0.3745]	[0.3242, 0.4044]	[0.5956, 0.6758]

3.3 Paired checks ของ 8B BF16

Comparator	delta balanced accuracy	delta recall NORMAL	delta recall PNEUMONIA	McNemar discordant	p-value	ผ่าน numeric gate
8B NF4	-0.1591	+0.0638	-0.3820	158	1.30×10^{-11}	ไม่ผ่าน
Best local: 4B BF16	-0.2687	+0.0319	-0.5693	249	1.80×10^{-20}	ไม่ผ่าน

ค่า p ที่ต่ำในตารางนี้แสดงความแตกต่างแบบ paired แต่ทิศทางเป็นผลเสียต่อ 8B BF16 จึงไม่ใช่หลักฐานสนับสนุน candidate

3.4 Runtime ของ quality pass

Experiment B รัน deterministic pass หนึ่งรอบต่อ profile ตัวเลขนี้ไม่ใช่ five-round benchmark จึงรายงานเป็นค่ารอบเดียว

Profile	Load s	Generation s	Pipeline s	Generation img/h	Pipeline img/h	Amortized gen p50/p95	Peak alloc/reserved GiB	Peak RSS GiB
2B BF16	22.116	148.219	173.187	14,573.1	12,472.0	0.2578 / 0.2954	4.04 / 4.08	4.69
4B BF16	17.818	185.702	205.088	11,631.5	10,532.0	0.3298 / 0.3786	8.36 / 8.40	8.99
8B NF4	69.111	256.426	271.030	8,423.5	7,969.6	0.4679 / 0.5374	6.15 / 6.22	17.13
8B BF16	70.551	168.196	183.084	12,842.2	11,797.8	0.2762 / 0.3790	16.43 / 16.46	17.04

4. Experiment C1 - Batch scaling บน A100 หนึ่งใบ

ใช้ 4b-bf16, 1,000 images, 5 รอบต่อ batch ไม่มี OOM และทุก prediction มี status ok

Batch	Load s	Generation s	Pipeline s	Generation img/h	Pipeline img/h	Amortized gen p50	p95	Peak alloc GiB	Peak reserved GiB
1	5.254	305.282	330.451	11,792.4	10,894.2	0.3297	0.3711	8.36	8.39
2	5.349	182.314	205.996	19,746.1	17,476.0	0.1884	0.2112	8.46	8.64
4	5.290	106.116	130.715	33,925.3	27,540.8	0.1049	0.1161	8.61	8.91
8	5.309	63.410	86.509	56,773.7	**41,614.4**	0.0633	0.0674	8.92	9.62

Batch-level latency เพิ่มตามขนาด batch ขณะที่ amortized latency ลดลง:

Batch	Batch generation p50	p95	Batch pipeline p50	p95	Allocated GPU-h/1,000 images
1	0.3297	0.3711	0.3499	0.4003	0.0995
2	0.3769	0.4224	0.4180	0.4781	0.0640
4	0.4197	0.4643	0.5263	0.5968	0.0417
8	0.5067	0.5395	0.6931	0.7934	**0.0290**

Peak process RSS ของ batch 1/2/4/8 เท่ากับ 8.99/9.00/8.99/8.99 GiB ตามลำดับ

กฎ highest valid median pipeline throughput เลือก batch 8 สำหรับ C2

5. Experiment C2 - Multi-GPU strong scaling

ใช้ 4b-bf16, per-GPU batch 8 และ workload คงที่ 2,000 ภาพต่อรอบ รวม 5 รอบ ต่อจำนวน GPU แต่ละ rank ได้ shard ไม่ซ้ำและ CPU affinity 16 cores/rank

GPUs	Median generation s	Median pipeline s	Median complete-round wall s	Aggregate img/h	Speedup	Efficiency	Peak alloc/rank GiB	Peak reserved/rank GiB	Peak RSS/rank GiB
1	129.540	176.549	192.296	40,781.8	1.000	100.00%	8.93	9.71	9.00
2	65.584	88.691	105.495	81,180.7	1.991	99.53%	8.93	9.56	8.99
4	33.517	45.105	64.905	159,628.9	3.914	97.86%	8.93	9.77	8.99

GPUs	Scaling gate	ผล	Allocated GPU-h/1,000 images
1	baseline	-	0.0267
2	efficiency >=80%	ผ่าน	0.0296
4	efficiency >=70%	ผ่าน	0.0366

การเพิ่ม GPU ลด turnaround แต่ใช้ GPU-hours ต่อ 1,000 ภาพมากขึ้นเล็กน้อย ผล unpinned และ CPU-pinned รุ่นแรกถูกเก็บเป็น diagnostic runs ไม่ถูกใช้แทนผล final เพราะมี CPU contention/inter-op-thread confound

6. Set D - 30B/32B บน Development 600 ภาพ

Set D เป็น exploratory Development extension เพราะ 30B/32B ไม่อยู่ใน candidate list เดิมของ Experiment B แต่ใช้ manifest และ comparator 4B ชุดเดียวกันเพื่อให้ paired comparison ตรวจสอบได้ ทั้งสองโมเดลรัน 2 รอบและ prediction hash ตรงกันข้ามรอบ

6.1 Patient-level metrics

Profile	n	Accuracy	Balanced accuracy	Macro-F1	Uncertainty	Coverage	Image BA
30B MoE BF16	549	0.7231 [0.6867, 0.7596]	0.7271 [0.6909, 0.7628]	0.7279 [0.6908, 0.7649]	0.0255	0.9745	0.7400
32B dense BF16	549	0.7322 [0.6958, 0.7705]	0.7335 [0.6968, 0.7711]	0.7436 [0.7071, 0.7805]	0.0310	0.9690	0.7533

Profile	Class	Support	Predicted	Precision	Recall	F1
30B MoE	NORMAL	282	193	0.8497	0.5816	0.6905
30B MoE	PNEUMONIA	267	342	0.6813	0.8727	0.7652
32B dense	NORMAL	282	243	0.7984	0.6879	0.7390
32B dense	PNEUMONIA	267	289	0.7197	0.7790	0.7482

Profile	NORMAL recall CI	PNEUMONIA recall CI	Uncertainty CI	Coverage CI
30B MoE	[0.5213, 0.6384]	[0.8277, 0.9101]	[0.0128, 0.0401]	[0.9599, 0.9872]
32B dense	[0.6348, 0.7447]	[0.7302, 0.8277]	[0.0182, 0.0455]	[0.9545, 0.9818]

6.2 Paired delta เทียบ 4B BF16

Candidate	Metric	Delta	95% paired-bootstrap CI
30B MoE	Accuracy	+0.0419	[+0.0036, +0.0820]
30B MoE	Balanced accuracy	+0.0404	[+0.0025, +0.0789]
30B MoE	Macro-F1	+0.0478	[+0.0077, +0.0902]
30B MoE	Uncertainty rate	-0.0036	[-0.0164, +0.0091]
30B MoE	Coverage	+0.0036	[-0.0091, +0.0164]
30B MoE	Recall NORMAL	+0.0957	[+0.0355, +0.1596]
30B MoE	Recall PNEUMONIA	-0.0150	[-0.0599, +0.0300]
32B dense	Accuracy	+0.0510	[+0.0073, +0.0984]
32B dense	Balanced accuracy	+0.0468	[+0.0043, +0.0937]
32B dense	Macro-F1	+0.0636	[+0.0188, +0.1129]
32B dense	Uncertainty rate	+0.0018	[-0.0128, +0.0182]
32B dense	Coverage	-0.0018	[-0.0182, +0.0128]
32B dense	Recall NORMAL	+0.2021	[+0.1277, +0.2766]
32B dense	Recall PNEUMONIA	-0.1086	[-0.1610, -0.0524]

Candidate	Correct candidate/wrong comparator	Wrong candidate/correct comparator	Discordant	McNemar p
30B MoE	71	48	119	0.0433
32B dense	102	74	176	0.0415

30B ไม่ผ่านเกณฑ์ delta balanced accuracy >=0.05 แม้ recall margin และ nominal McNemar ผ่าน ส่วน 32B ไม่ผ่านทั้ง delta >=0.05 และเกณฑ์ class-recall drop >=-0.03 การทดสอบ candidate สองตัวกับ comparator เดียวกันยังไม่มี multiplicity rule ที่ freeze ใน SAP; หากใช้ Bonferroni alpha=0.025 ค่า p ทั้งสองจะไม่ผ่าน

6.3 Performance ของ large models

Profile	Round	Load s	Generation s	Pipeline s	Generation img/h	Pipeline img/h	Batch generation p50/p95	Batch pipeline p50/p95	Peak alloc GiB	Peak reserved GiB
30B MoE	1	59.137	479.996	496.478	4,500.0	4,350.6	0.8606 / 0.9521	0.8828 / 0.9767	58.72	60.19
30B MoE	2	33.644	464.806	480.564	4,647.1	4,494.7	0.8365 / 0.9239	0.8555 / 0.9465	58.72	60.19
32B dense	1	68.282	405.552	430.165	5,326.1	5,021.3	0.7663 / 0.8552	0.7917 / 0.8905	62.36	62.45
32B dense	2	35.619	406.132	420.998	5,318.5	5,130.7	0.7683 / 0.8611	0.7831 / 0.8834	62.36	62.45

Peak process RSS อยู่ที่ประมาณ 58.72 GiB สำหรับ 30B และ 62.96 GiB สำหรับ 32B ต่อ process โดยน้ำหนักถูกกระจายข้าม A100 สองใบ รอบแรกมี cold-cache/load overhead สูงกว่า แต่ generation time ของ 32B แทบไม่เปลี่ยนระหว่างรอบ

7. Local capacity ceiling

การทดสอบบังคับ BF16 weights ทั้งหมดลง CUDA device 0 โดยไม่ใช้ CPU/disk offload และตรวจว่าไฟล์น้ำหนักครบตาม registry ก่อนโหลด

Profile	Weight files	Weight bytes	Standard loader	No-warm-up diagnostic	Peak allocated	Peak reserved
30B MoE	13	62,141,618,016	OOM ขอ 10.30 GiB	OOM ขอเพิ่ม 768 MiB	10,410,336,256 B	10,550,771,712 B
32B dense	14	66,714,912,872	OOM ขอ 10.30 GiB	OOM ขอเพิ่ม 80 MiB	10,843,056,128 B	10,863,247,360 B

Standard-loader OOM เกิดที่ speculative allocator warm-up จึงใช้เป็นหลักฐานรอง ส่วน no-warm-up run โหลด weights จริงจนเหลือหน่วยความจำเพียงเล็กน้อยแล้ว OOM เป็นหลักฐานหลักว่า local card ไม่สามารถรองรับ BF16 model ทั้งสองตัว

8. Secondary image-level metrics และ confusion matrices

8.1 Image-level summary

Profile	n	Accuracy	Balanced accuracy	Macro-F1	Uncertainty	Coverage	Status ok	Parse failures
2B BF16	600	0.6733	0.6733	0.6470	0.0000	1.0000	600	0
4B BF16	600	0.7000	0.7000	0.6884	0.0000	1.0000	600	0
8B NF4	600	0.5967	0.5967	0.5941	0.0117	0.9883	600	0
8B BF16	600	0.4417	0.4417	0.5216	0.3267	0.6733	600	0

Profile	n	Accuracy	Balanced accuracy	Macro-F1	Uncertainty	Coverage	Status ok	Parse failures
30B MoE	600	0.7400	0.7400	0.7352	0.0017	0.9983	600	0
32B dense	600	0.7533	0.7533	0.7528	0.0000	1.0000	600	0

`status` ok หมายถึง pipeline และ parser ทำงานครบ ไม่ได้หมายความว่าคำตอบไม่เป็น `UNCERTAIN`

8.2 Image-level per-class metrics

Profile	Class	Support	Predicted	Precision	Recall	F1
2B BF16	NORMAL	300	136	0.8824	0.4000	0.5505
2B BF16	PNEUMONIA	300	464	0.6121	0.9467	0.7435
4B BF16	NORMAL	300	184	0.8261	0.5067	0.6281
4B BF16	PNEUMONIA	300	416	0.6442	0.8933	0.7486
8B NF4	NORMAL	300	219	0.6484	0.4733	0.5472
8B NF4	PNEUMONIA	300	374	0.5775	0.7200	0.6409
8B BF16	NORMAL	300	246	0.6585	0.5400	0.5934
8B BF16	PNEUMONIA	300	158	0.6519	0.3433	0.4498
30B MoE	NORMAL	300	213	0.8404	0.5967	0.6979
30B MoE	PNEUMONIA	300	386	0.6865	0.8833	0.7726
32B dense	NORMAL	300	272	0.7794	0.7067	0.7413
32B dense	PNEUMONIA	300	328	0.7317	0.8000	0.7643

8.3 Confusion matrices

คอลัมน์เรียงเป็น true NORMAL -> predicted NORMAL/PNEUMONIA/UNCERTAIN และ true PNEUMONIA -> predicted NORMAL/PNEUMONIA/UNCERTAIN

Profile	Level	N->N	N->P	N->U	P->N	P->P	P->U
2B BF16	patient	110	165	7	13	251	3
2B BF16	image	120	180	0	16	284	0
4B BF16	patient	137	134	11	25	237	5
4B BF16	image	152	148	0	32	268	0
8B NF4	patient	128	146	8	64	187	16
8B NF4	image	142	158	0	77	216	7
8B BF16	patient	146	48	88	70	85	112
8B BF16	image	162	55	83	84	103	113
30B MoE	patient	164	109	9	29	233	5
30B MoE	image	179	121	0	34	265	1
32B dense	patient	194	81	7	49	208	10
32B dense	image	212	88	0	60	240	0

9. Resource use และ operational metrics

กลุ่มงาน	Job IDs	GPU-hours
Large-model feasibility 20 images	6293741-6293742	0.2144
Experiment A	6293861-6293863	1.6119
Experiment B	6293864-6293867	0.3319
Original C1 diagnostic	6293868-6293871	1.2081
Selected 4B C1	6294007-6294010	1.1711
C2 unpinned diagnostic	6294156-6294158	1.5625
C2 CPU-pinned diagnostic	6294184-6294186	1.0075
C2 final CPU-pinned v2	6294203-6294205	0.9286
Set D 30B/32B	6295763-6295764	1.2839
รวม		**9.3200**

Selected job queue waits และ allocation elapsed:

งาน	GPUs	Queue wait	Allocation elapsed	Result
A 2B / 4B / 8B	1	5 s	25:26 / 30:37 / 40:40	complete
C1 4B batch 1/2/4/8	1	00:30 / 06:54 / 10:25 / 14:28	29:51 / 19:12 / 12:31 / 08:42	complete
C2 final 1/2/4 GPU	1/2/4	2 s	16:01 / 08:53 / 05:29	complete
Set D 30B / 32B	2	30 s	20:13 / 18:18	complete

Quota snapshot ล่าสุดก่อน Set D เหลือ 4,366.41/115,056.00 shared SHr (3.80%) หน่วย SHr ไม่ถูกแปลงเป็น guaranteed A100 GPU-hours เพราะไม่มี conversion policy ที่ยืนยันแล้ว

10. การตรวจความครบถ้วนและ reproducibility

- State files 25 ชุดมีสถานะ `complete`
- Automated tests ผ่าน 9/9
- C2 ตรวจครบ 15 รอบว่าแต่ละ image ID ปรากฏครั้งเดียว ไม่มี shard ซ้ำหรือหาย
- Set D evaluation checksum ผ่านทั้ง 30B และ 32B
- Set D prediction hashes ตรงกันระหว่างรอบ 1 และ 2 ทั้งสองโมเดล
- Execution pack ตรวจผ่าน 73/73 ไฟล์; manifest SHA-256: `bced27c6fe894d3254aaf2fd1885d384d7eb8e628ef9358411bf79fd3aa575c4`
- Evidence manifest ครอบคลุม 1,199 ไฟล์; SHA-256: `bce7df5296a584f1445d2ecae9498b1aa2ec44287fb0a0b5e44fcdfb9f12a9c9`
- รายงานฉบับนี้สร้างหลัง evidence manifest จึงไม่ใส่ตัวเองใน manifest เพื่อหลีกเลี่ยง self-reference; checksum ของรายงานอยู่ใน `FULL_EXPERIMENT_REPORT_TH.md.sha256`

มี code drift ระหว่าง Experiment A: `inference.py` เพิ่ม CPU/thread telemetry และ จำกัด local threads ระหว่าง local 4B round 1 กับ round 2-5 การเปรียบเทียบธรรมชาติ ใน 4B พบผลต่างประมาณ 0.3% ซึ่งไม่เปลี่ยนทิศทางของ speed result แต่ยังต้องถือเป็น ข้อจำกัดด้าน provenance และต้อง freeze pack ใหม่ก่อน confirmatory

11. Metric ที่ยังไม่มีหลักฐาน

- ไม่มี confirmatory Test metric เพราะ Test ยังล็อกอยู่
- ไม่มี single complete-turnaround timestamp ตั้งแต่เริ่ม stage model จนเก็บผลกลับ local; มีเฉพาะ queue, allocation elapsed, per-round wall และ model-loading time
- ไม่มี energy consumption, power efficiency หรือค่าใช้จ่ายทางการเงิน
- C2 ไม่มี confidence interval ของ speedup/efficiency
- ไม่มี post-Set-D quota snapshot
- ยังไม่มี multiplicity procedure ที่นักสถิติอนุมัติสำหรับ large candidates สองตัว
- ไม่มี human HPC operator sign-off, frozen SAP, IRB/privacy determination หรือ confirmatory access authorization

12. ข้อสรุปและคำตัดสินตามเกณฑ์ที่กำหนด

Gate	เกณฑ์	ผล	คำตัดสิน
Hardware speed	A100 speedup >=1.5 และ lower CI >1	0.652-0.786	ไม่ผ่าน
8B BF16 quality	delta BA >=+0.05, p<0.05, recall drop >=-0.03	delta BA -0.2687 vs 4B; recall PNEUMONIA -0.5693	ไม่ผ่าน
30B quality	delta BA >=+0.05, p<0.05, recall drop >=-0.03	+0.0404; p=0.0433; min recall delta -0.0150	ไม่ผ่าน margin
32B quality	เงื่อนไขเดียวกัน	+0.0468; p=0.0415; PNEUMONIA -0.1086	ไม่ผ่าน margin และ recall
Batch scaling	throughput สูงสุดโดยไม่ OOM/failure	batch 8, 41,614 img/h	เลือก batch 8
2-GPU scaling	efficiency >=80%	99.53%	ผ่าน
4-GPU scaling	efficiency >=70%	97.86%	ผ่าน
Budget	<=24 GPU-hours	9.3200	ผ่าน

สำหรับ workload batch 1 และโมเดลที่พอดีกับ local GPU ควรใช้ RTX 5070 หากเป้าหมาย คือเวลา inference ต่อ GPU ส่วน LANTA เหมาะเมื่อจำเป็นต้องใช้ 30B/32B, batch ใหญ่ หรือ parallel throughput หลาย GPU ผล Development แสดงว่า large models เพิ่มคุณภาพ บางส่วน แต่ยังไม่ถึงเกณฑ์ที่ตั้งไว้ จึงไม่ควรเปลี่ยน comparator หรือผ่อน threshold ย้อนหลังจากผลนี้

Confirmatory analysis ต้องรอการปิด BLOCK-01-04, frozen SAP, touched-test history, multiplicity rule และสิทธิ์เปิด labels ก่อน รายงานนี้ไม่ปลด lock ดังกล่าว

13. แหล่งหลักฐาน

- `systems-summary.json` และ `systems-summary.csv`: Experiment A/C1/C2 aggregate
- `lanta/B-development/*/evaluation/metrics.json`: Experiment B metrics

- `lanta/B-development/quality-summary.json`: selection rule และ 8B comparisons
- `lanta/C1-selected-4b-bf16/selection.json`: batch selection
- `lanta/C2-selected-4b-bf16-cpu-pinned-v2/`: final scaling states/logs
- `lanta/D-large-development/*/evaluation/metrics.json`: Set D quality/comparison
- `artifacts/local-capacity-30b*.json`, `artifacts/local-capacity-32b*.json`: local OOM evidence
- `slurm-accounting.tsv`: queue/start/end/exit/resources/MaxRSS
- `experiment-evidence.sha256`: file-level evidence integrity