VLM Medical Image Classification

Progress Update · Qwen3-VL 2B / 4B / 8B · RTX 5070 vs A100

(6914500738) นิจวรีย์ บุญเอื้อ
(6914500711) ธนภัทร เอี่ยมอาจ
(6914500703) ณัฏฐพล เรืองวราพิชญ์

คำถามจากครั้งก่อน

Capacity = รันรุ่นใหญ่ · Throughput = ภาพต่อชั่วโมง · Quality = ความถูกต้อง

01 Capacity

A100 รันโมเดลขนาดใหญ่ (8B) ที่ RTX 5070 โหลดไม่ไหวได้หรือไม่?

02 Throughput

ส่งภาพหลายรูปพร้อมกันหรือเพิ่ม GPU แล้วประมวลผลภาพได้มากขึ้นเท่าไร?

03 Quality

ตอบตรงคำตอบอ้างอิงมากขึ้นไหม และเมื่อใช้โมเดลกับ prompt เดียวกัน ผลในแต่ละภาพตรงกันไหม?

A = เทียบเครื่อง B = ความถูกต้อง C = ส่งหลายภาพพร้อมกัน / หลาย GPU

Batch คือส่งหลายภาพพร้อมกัน

ภาพ 1
+ prompt เดียวกัน

ภาพ 2
+ prompt เดียวกัน

ภาพ 3
+ prompt เดียวกัน

ภาพ 4
+ prompt เดียวกัน

↓

โมเดลสร้างคำตอบ 1 ครั้ง

↓

ได้ผลทำนายแยก 4 รายการ

พรอมป์ที่ใช้จริงในการทดลอง


```
PROMPT = (
    'Classify this pediatric AP chest X-ray as NORMAL or PNEUMONIA. Return only '
    'one JSON object with exactly one key: {"label":"NORMAL|PNEUMONIA|UNCERTAIN"}. '
    'Use UNCERTAIN when the image is insufficient. Do not return Markdown or explanation.'
)
```

ฟ้า: งานจำแนก ส้ม: รูปแบบคำตอบ แดง: กรณี UNCERTAIN และข้อห้าม

ข้อมูลและวิธีวัดรอบนี้

A	1,000 ภาพไม่ซ้ำ · ชุดเดิม 5 รอบ	RTX 5070 vs A100 · batch 1
B	600 ภาพ · 300/300 ต่อคลาส	เทียบ RTX 5070 กับ A100
C1	1,000 ภาพ × 5 รอบต่อ batch	batch 1 / 2 / 4 / 8
C2	2,000 ภาพ × 5 รอบต่อ GPU	GPU 1 / 2 / 4 ใบ · งาน 2,000 ภาพคงที่

เวลาที่วัดในงานทดลอง

เวลาแต่ละชื่อครอบคลุมคนละช่วง

เวลาที่วัด	เริ่ม → จบ	การใช้
โหลดโมเดล **model_loading_seconds**	เริ่มโหลดโมเดล/processor → พร้อมใช้งาน	โค้ดวัด · แยก
สร้างคำตอบ **generation_seconds**	ก่อน generate → GPU สร้างคำตอบเสร็จ	โค้ดวัด · อยู่ใน pipeline
อ่านภาพจนได้คำตอบ **pipeline_seconds**	ก่อนเปิดภาพ → หลัง decode/parse คำตอบ	**โค้ดวัด · ใช้คิด A/C**
รันหนึ่งรอบ **elapsed_seconds**	เริ่ม subprocess → process จบ (A/B/C1)	วัดแยก · ไม่ใช้คิด
รันหลาย GPU **wall_seconds**	launcher เริ่ม rank → ทุก rank จบ (C2)	วัดแยก · ไม่ใช้คิด
รอคิว LANTA **Queue wait**	ส่งงาน SLURM → เริ่มได้รับ GPU	scheduler · แยก
ใช้ GPU บน LANTA **Allocation elapsed**	เริ่มได้รับ GPU → คืน GPU	scheduler · แยก

Capacity · โมเดลที่ลองบน RTX และ A100

ผลการรัน 4 แบบ · จำนวนภาพที่สำเร็จและข้อมูล VRAM ที่บันทึกไว้

โมเดล	RTX 5070 · 12 GB	A100 · 40 GB
2B BF16	**สำเร็จครบ 1,000 ภาพ** VRAM สูงสุด 4.06 GiB	**สำเร็จครบ 1,000 ภาพ** VRAM สูงสุด 4.04 GiB
4B BF16	**สำเร็จครบ 1,000 ภาพ** VRAM สูงสุด 8.38 GiB	**สำเร็จครบ 1,000 ภาพ** VRAM สูงสุด 8.36 GiB
8B NF4	**สำเร็จครบ 1,000 ภาพ** VRAM สูงสุด 6.18 GiB	**สำเร็จครบ 1,000 ภาพ** VRAM สูงสุด 6.15 GiB
8B BF16	**Out of memory · pilot เดิม** บันทึกไว้ราว 9.70 GiB	**สำเร็จครบ 600 ภาพ** VRAM สูงสุด 16.43 GiB

2B / 4B / 8B NF4: A · 1,000 ภาพ/รอบ × 5 รอบ, batch 1 · VRAM = มัธยฐานของค่าสูงสุด

8B BF16: RTX เป็นผล pilot เดิม; A100 เป็นผล B 600 ภาพ 1 รอบ · คนละชุดภาพและคนละรอบทดลอง

A · ความเร็วต่อ GPU

batch 1 · 1 GPU · 1,000 ภาพไม่ซ้ำ (859 ผู้ป่วย) · ชุดเดิม 5 รอบ

RTX 5070 ใช้เวลาประมวลผลภาพ (pipeline) น้อยกว่า A100 ทั้ง 3 แบบที่ทดสอบ

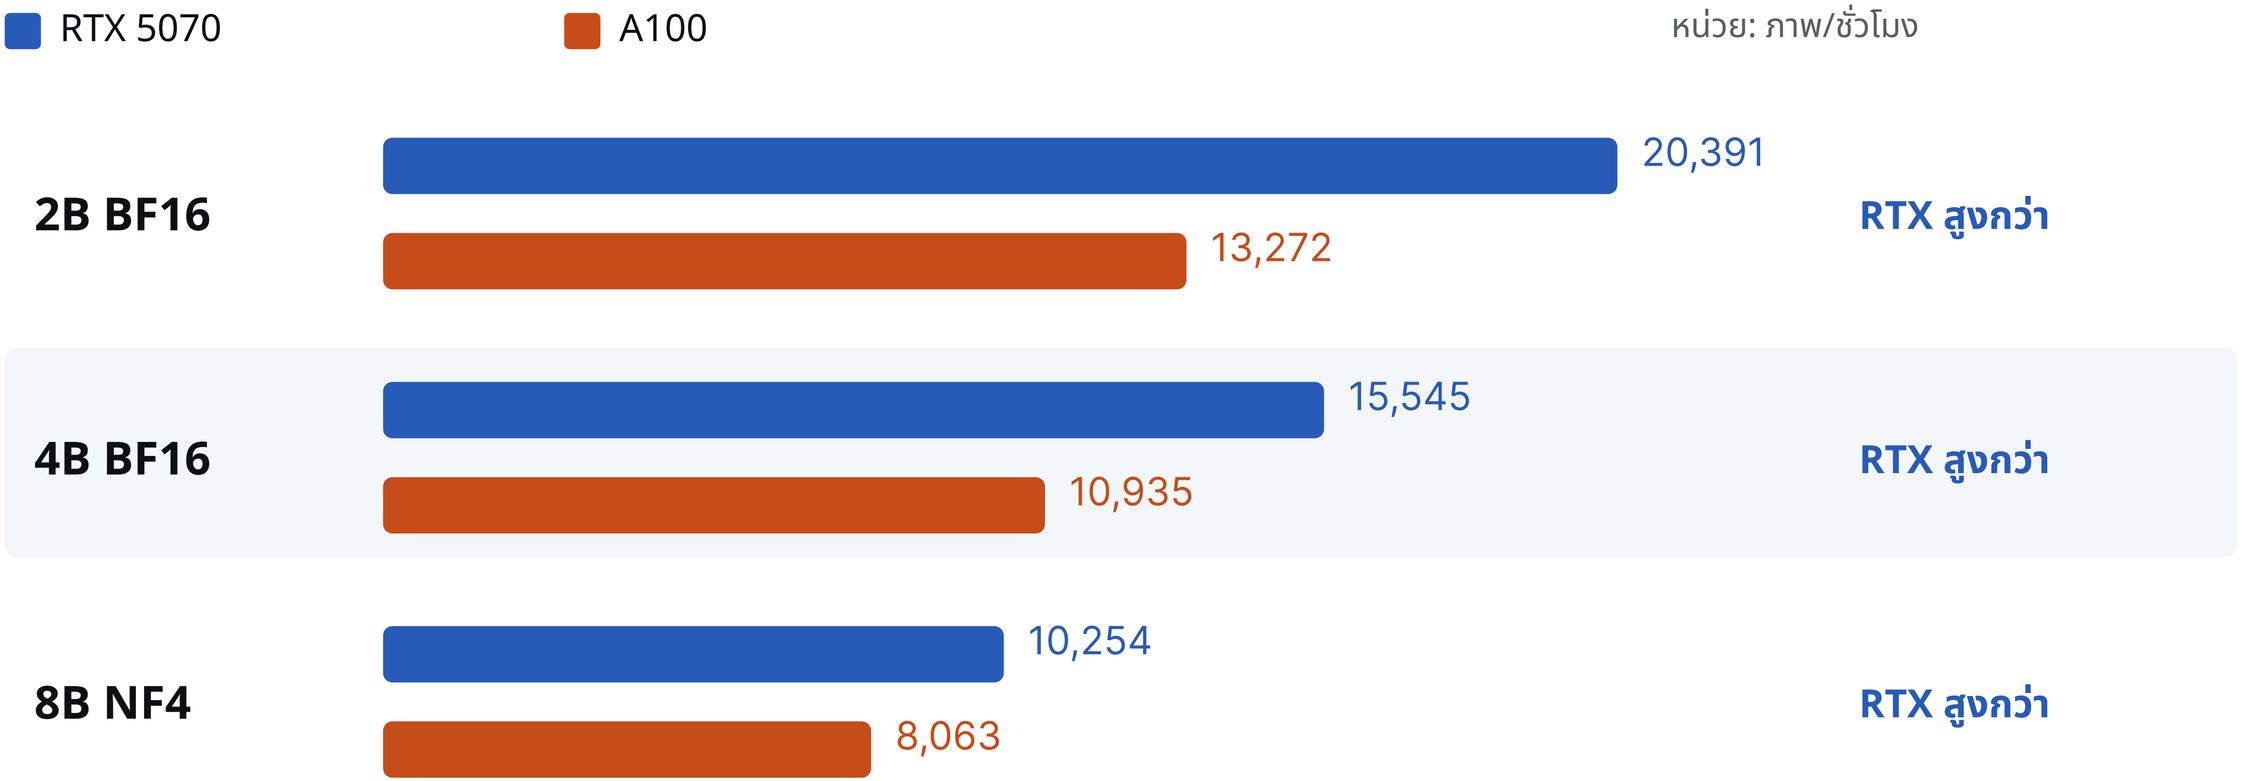
โมเดล	RTX เวลาประมวลผล [s]	A100 เวลาประมวลผล [s]
2B BF16	175.632	269.218
4B BF16	231.581	329.219
8B NF4	337.121	428.675

> **เวลา pipeline [s] = เริ่มก่อนเปิดภาพ → จบหลัง decode/parse คำตอบ**
> 4B รอบ 3 (gen + ขั้นตอนอื่น): RTX 212.803 + 18.778 = 231.581 s | A100 304.437 + 24.782 = 329.219 s

เวลาในตาราง = รอบที่ให้อัตราส่วนค่ากลาง: 2B/4B รอบ 3 · 8B รอบ 5
ไม่รวม model load/queue · Python/PyTorch/CUDA ต่างเวอร์ชัน จึงเทียบแพลตฟอร์ม

A · ภาพต่อชั่วโมง เมื่อส่งทีละภาพ

1 GPU ต่อเครื่อง · batch 1 · 1,000 ภาพชุดเดียวกัน · รัน 5 รอบ



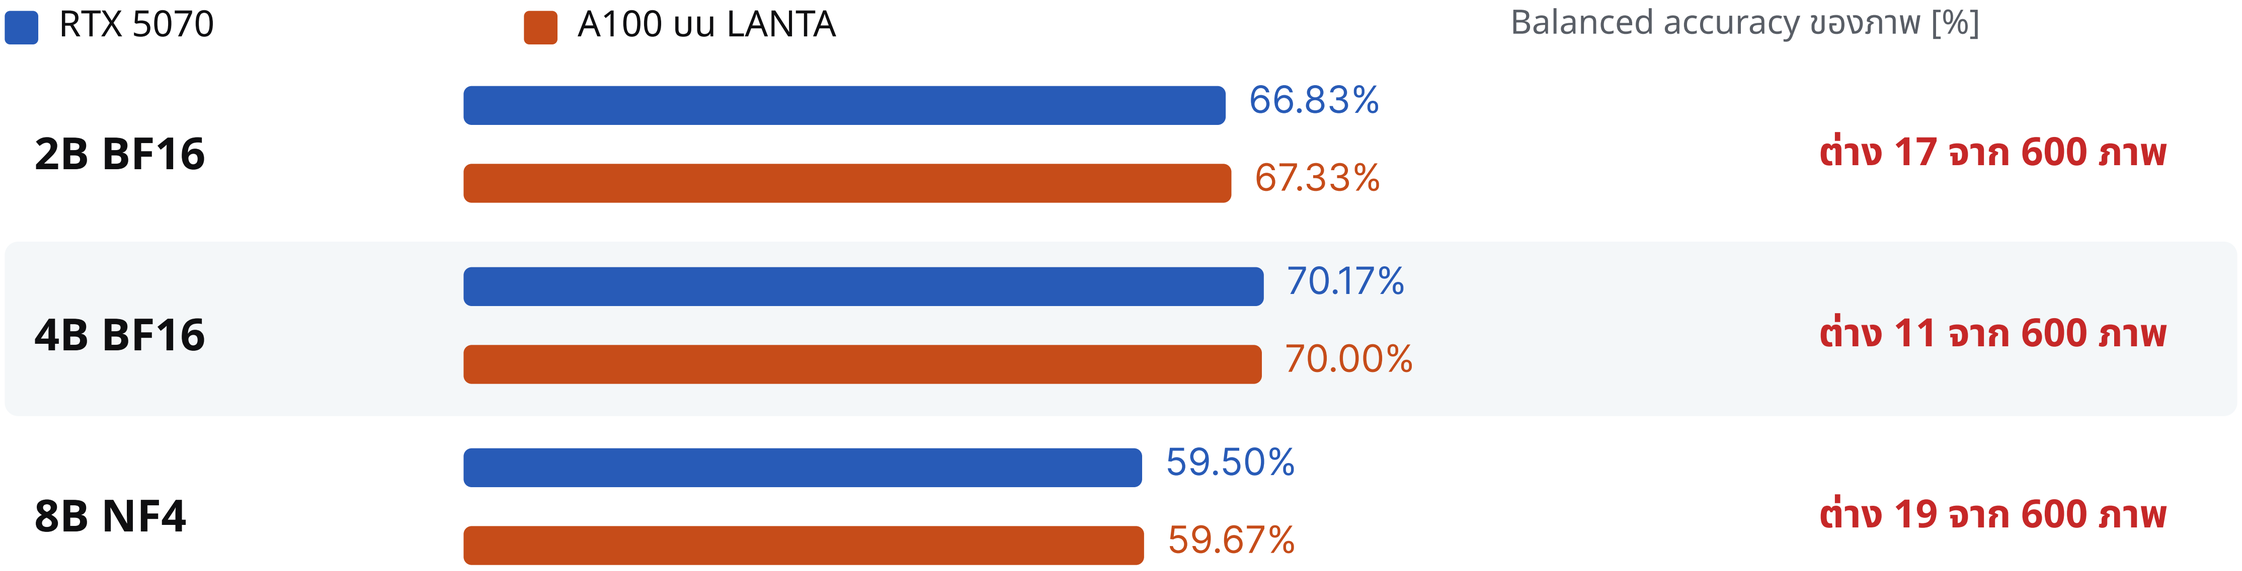
ภาพ/ชม. คำนวณจากเวลา pipeline · ไม่รวมโหลดโมเดลหรือรอคิว · Python/PyTorch/CUDA ต่างเวอร์ชัน

B · ความถูกต้องในการจำแนกภาพ

ภาพเดียวกัน 600 ภาพ · balanced accuracy = เฉลี่ยอัตราตอบถูก 2 คลาส

คำถาม 1 · คำทำนาย RTX กับ A100 เหมือนกันไหม? ต่าง 17, 11, 19 จาก 600 ภาพ

คำถาม 2 · เพราะอะไร? ยังต้องตรวจหลักฐานก่อนสรุป



8B BF16 รันเฉพาะ A100: balanced accuracy 44.17% · UNCERTAIN 32.67%

RTX: คัด 600 ภาพจากผล A; A100: ผล B บนภาพเดียวกัน · ยังไม่มี local B run โดยตรง
Config hash และ model revision ของผล A สองเครื่องตรงกัน · สาเหตุที่คำทำนายต่างยังไม่ยืนยัน

C · Batch และหลาย GPU

4B BF16 บน A100 · C1 = 1,000 ภาพ · C2 = 2,000 ภาพคงที่

C1 · ส่งภาพพร้อมกัน / 1 GPU

3.82× ภาพ/ชม.: batch 8 เทียบ batch 1

Batch	จำนวนภาพต่อชั่วโมง [ภาพ/ชม.]
1	10,894
2	17,476
4	27,541
8	**41,614**

ภาพ/ชม. = 3,600 × ภาพ ÷ Pipeline total [s]

หารรายรอบแล้วรายงานมัธยฐาน 5 รอบ

C2 · เพิ่มจำนวน GPU / batch 8

GPU	เวลา pipeline มัธยฐาน [s]	เร็วขึ้น [×]
1	176.549	**1.000**
2	88.691	**1.991**
4	45.105	**3.914**

ประสิทธิภาพ = (เร็วขึ้น ÷ GPU) × 100: 2 ใบ 99.53% · 4 ใบ 97.86%

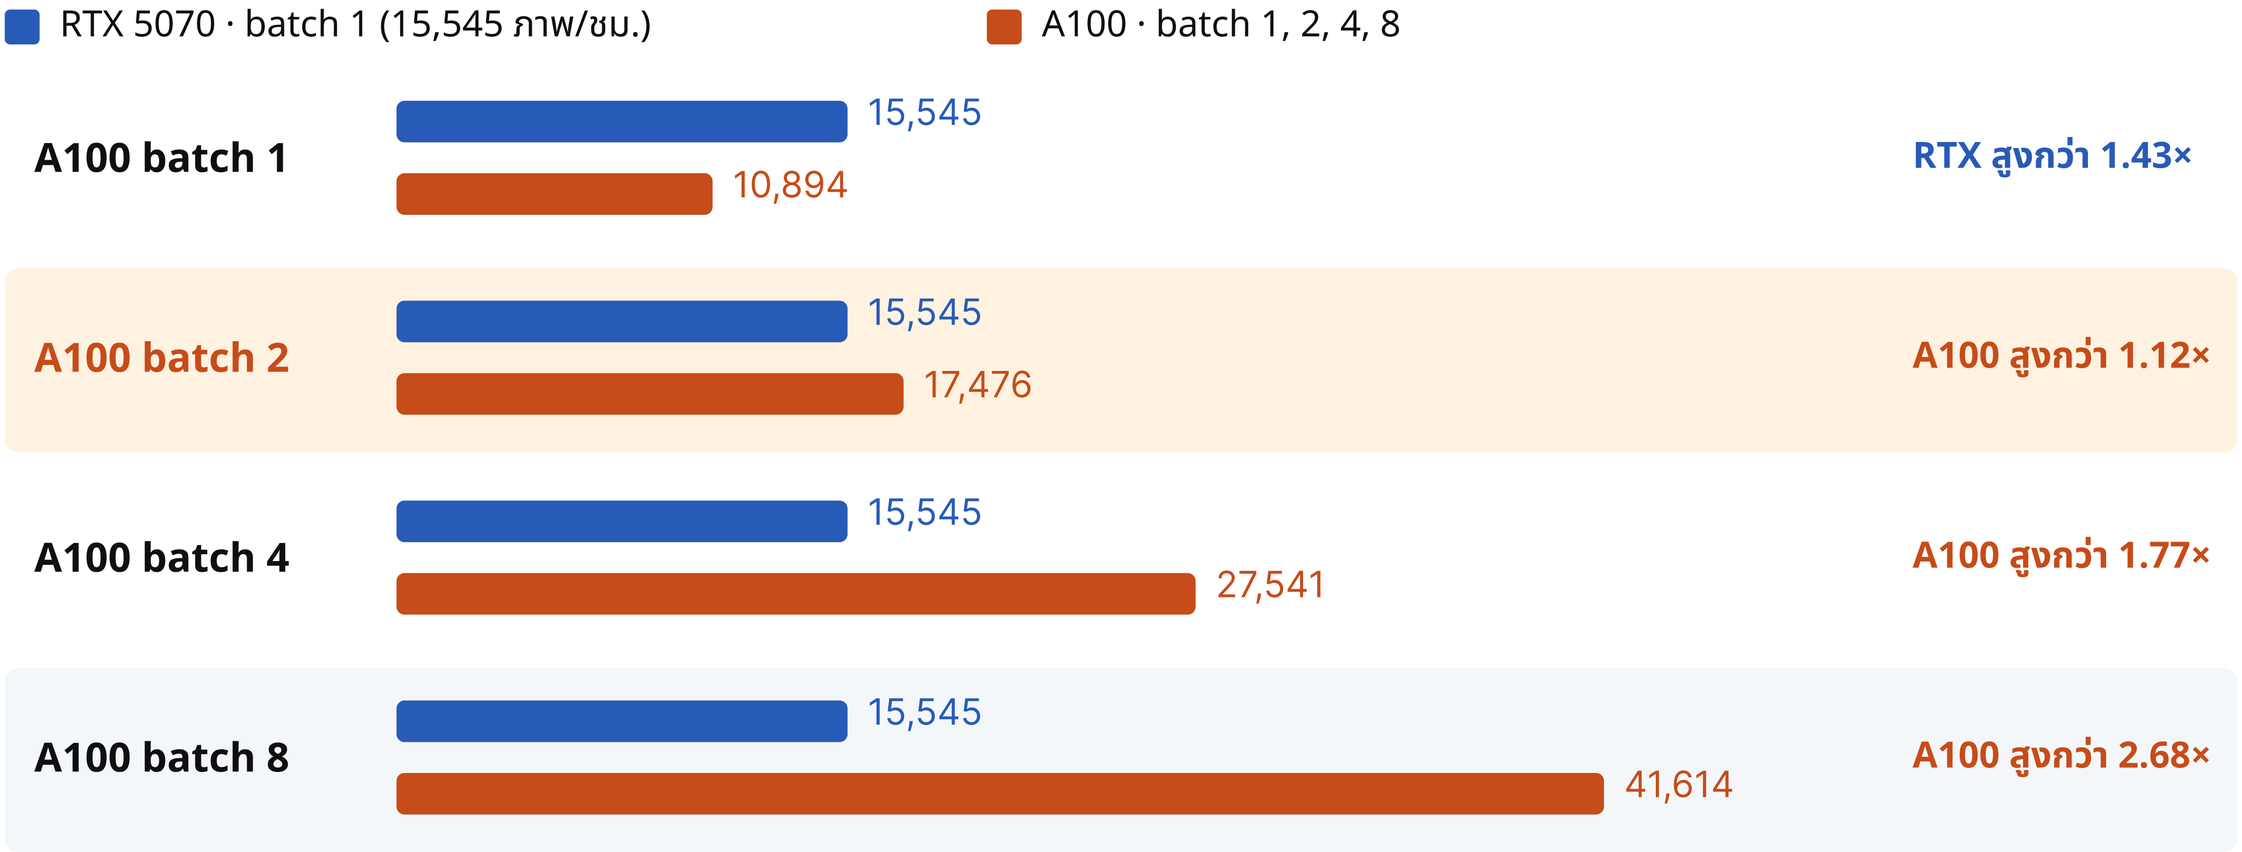
เร็วขึ้นเมื่อเพิ่ม GPU = ค่ากลางเวลา 1 GPU ÷ ค่ากลางเวลา k GPU

เวลา pipeline ที่ใช้คิด: อ่าน/ย่อภาพ → tensor/GPU → generate → decode/parse

รวม batch สำเร็จหลัง warm-up; C2 ใช้ GPU ที่ช้าที่สุดต่อรอบ → ค่ากลาง 5 รอบ · ไม่รวมโหลดโมเดล / เวลาทั้งรอบ / คิว

A100 batch 2 สูงกว่าค่า RTX 5070 batch 1

4B BF16 · GPU อย่างละ 1 ใบ · จำนวนภาพต่อชั่วโมง



RTX batch 1 จาก A เทียบ A100 จาก C1; RTX ยังไม่มีผล batch 2/4/8

สรุปตามคำถามเดิม

ตอบเรียงตามคำถามจากหน้า 2

Capacity = รันรุ่นใหญ่ **Throughput = ภาพต่อชั่วโมง** **Quality = ความถูกต้อง**

01 Capacity

A100 รัน 8B BF16 ที่ RTX 5070 โหลดไม่ไหวได้ไหม?

ได้ — 8B BF16 รันครบ 600 ภาพบน A100

RTX เกิด OOM ใน pilot เดิม · A100 ใช้ VRAM สูงสุด 16.43 GiB

02 Throughput

ส่งหลายภาพพร้อมกันหรือเพิ่ม GPU แล้วได้ภาพต่อชั่วโมงมากขึ้นเท่าไร?

เพิ่มได้เมื่อใช้ batch / หลาย GPU

C1 batch 1 → 8: 10,894 → 41,614 ภาพ/ชม.
C2 4 GPU: เร็วขึ้น 3.914× เทียบ 1 GPU

03 Quality

ตอบถูกขึ้นไหม และเมื่อใช้โมเดลกับ prompt เดียวกัน ผลรายภาพตรงกันไหม?

8B BF16 ไม่เพิ่มความถูกต้อง; ผลรายภาพยังต่าง

4B: RTX 70.17% / A100 70.00% · A100 8B BF16 44.17%

2B/4B/8B NF4: RTX/A100 ต่าง 17/11/19 จาก 600 ภาพ · สาเหตุยังต้องตรวจ

A100 ไม่เร็วกว่า RTX 5070 ต่อ GPU ที่ batch 1 ในเงื่อนไขที่ทดสอบ

สิ่งที่จะทำต่อ

ปิดคำถามจากผลรอบนี้ก่อนประเมินยืนยันผล

01 **หาสาเหตุของผลรายภาพที่ต่าง**

ตรวจโค้ด / software stack และภาพที่ทำนายต่าง 17 / 11 / 19 ภาพ

ทดลองซ้ำภายใต้เงื่อนไขที่ตรึงแล้วก่อนอธิบายสาเหตุ

02 **เติมหลักฐานระบบ A/C**

ตรึง software stack · output tokens/sec · เวลารวมตั้งแต่เตรียมงานถึงได้ผล

หาช่วงความเชื่อมั่นของผลเมื่อเพิ่ม GPU

03 **ทดสอบคุณภาพรอบใหม่**

หลังอธิบายความต่าง ทดสอบพรอมป์ใหม่กับภาพชุดทดลองเพื่อลด UNCERTAIN ของ 8B BF16

เก็บพรอมป์เดิมเป็นจุดอ้างอิง

ยังไม่ได้ประเมินบนชุดภาพสำหรับยืนยันผลขั้นสุดท้าย